Sztuczna inteligencja w grafice komputerowej

Projekt nr 1

Maciej Malicki 347427

Spis treści

1. Zwiększanie rozdzielczości 2
   1.1. Przygotowanie danych i architektura 2
   1.2. Funkcja straty 2
   1.3. Wyniki 3
   1.4. Wnioski 5
2. Odszumianie 5
   2.1. Przygotowanie danych i architektura 5
   2.2. Funkcja straty 5
   2.3. Wyniki 6
   2.4. Wnioski 8

Zwiększanie rozdzielczości

1.1 Przygotowanie danych i architektura

Do wykonania zadania został użyty zbiór danych DIV2K: 800 obrazów treningowych i 100 walidacyjnych. Z każdego obrazu wycięto fragment o rozmiarach 256 x 256 pikseli.
Obrazy zostały zmniejszone do 32 x 32 oraz 64 x 64 pikseli za pomocą interpolacji bikubicznej. Następnie były one powiększane tą samą metodą do rozmiarów wejściowych i przekazywano do sieci.

Architektura autoenkodera:

1) Koder:
   a) Trzy bloki konwolucyjne o liczbie kanałów 32, 64 i 128. Między blokami został zastosowany pooling 2 x 2.
2) Blok środkowy:
   a) Blok konwolucyjny o liczbie kanałów 128 oraz Dropout2d z prawdopodobieństwem równym 0,5.
3) Dekoder:
   a) Dwa bloki, każdy złożony z warstwy dwukrotnego powiększania obrazu interpolacją biliniową oraz dwóch warstw konwolucyjnych.
   b) Po powiększeniu dołączano odpowiadające wyjście kodera przez konkatenację kanałów. Kolejne bloki zwracały odpowiednio 64 i 32 kanały.

Każdy blok konwolucyjny zawiera dwie konwolucje 3 × 3 z krokiem 1 i dopełnieniem 1. Po każdej zastosowano normalizację BatchNorm i aktywację LeakyReLU ze współczynnikiem 0,2.

1.2 Funkcja straty

Do zmierzenia start został wykorzystany błąd średniokwadratowy (MSE).

$$L_{\mathrm{MSE}} = \frac{1}{N}\sum_{i=1}^{N}\left(\hat{Y}_i - Y_i\right)^2$$

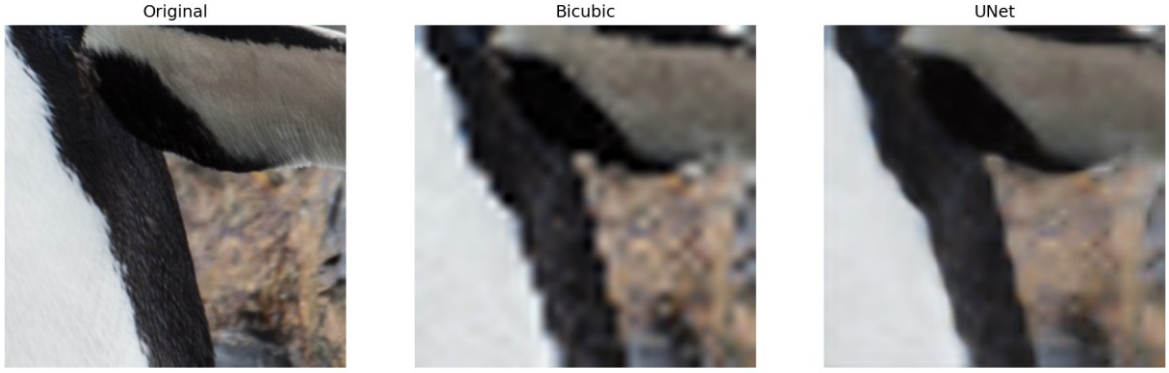
gdzie Y_i to rzeczywista wartość, a $\hat{Y}_i$to przewidywana wartość modelu.

- optymalizator Adam,
- współczynnik uczenia 10^{-4};
- 30 epok, batch size 2;
- random seed 42;
- wybór modelu o najmniejszej stracie walidacyjnej.

1.3 Wyniki

Metryki obliczano osobno dla każdego obrazu, a następnie uśredniano na 100 obrazach walidacyjnych. SNE oznacza sumę kwadratów błędów, a LPIPS obliczano z wykorzystaniem sieci VGG.

Rozdzielczość wejściowa	Metoda	SNE	PSNR	SSIM	LPIPS
32 x 32	Bicubic	2496,6145	20,7516	0,5167	0,5570
32 x 32	U-net	2103,8394	21,4250	0,5276	0,5338
64 x 64	Bicubic	1313,9662	23,9497	0,6904	0,3977
64 x 64	U-net	1089,6919	24,7777	0,7041	0,3676



Rysunek 1 Zwiększanie rozdzielczości 32 x 32 -> 256 x 256



Rysunek 2 Zwiększanie rozdzielczości 64 x 64 -> 256 x 256



Rysunek 3 Zwiększanie rozdzielczości 32 x 32 -> 256 x 256



Rysunek 4 Zwiększanie rozdzielczości 64 x 64 -> 256 x 256



Rysunek 5 Zwiększanie rozdzielczości 32 x 32 -> 256 x 256



Rysunek 6 Zwiększanie rozdzielczości 64 x 64 -> 256 x 256

1.4 Wnioski

U-Net poprawił wszystkie metryki względem interpolacji bikubicznej. Przyrost PSNR wyniósł około 0,67 dB dla wejścia 32 × 32 oraz 0,83 dB dla 64 × 64. Dla wejścia 32 × 32 model ogranicza artefakty powiększania, ale nie szczegółów oryginalnego obrazu. Obie metody uzyskują wyraźnie lepsze wyniki dla 64 × 64, ponieważ obraz wejściowy zawiera więcej informacji.

Odszumianie

2.1 Przygotowanie danych i architektura

Do realizacji zadania został wykorzystany już wcześniej przygotowany zbiór danych na potrzeby realizacji poprzedniego zadania. Wartości pikseli są normalizowane do przedziału [0, 1], a następnie dodawany jest szum Gaussa o odchyleniu standardowym σ = 0,01 lub σ = 0,03. W zadaniu została również wykorzystana wcześniej przygotowana architektura U-net.

Metodą bazową był denoise_bilateral z biblioteki scikit-image, z parametrami:

- sigma_color równym odchyleniu standardowemu dodanego szumu;
- sigma_spatial = 1;
- obsługą brzegów mode="reflect".

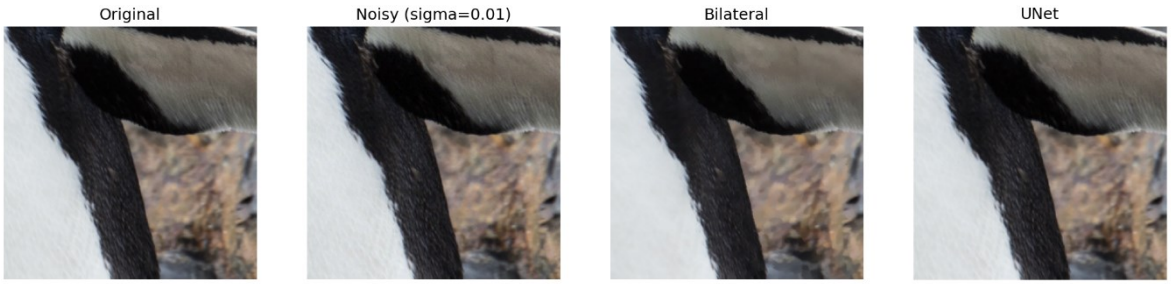
2.2 Funkcja straty

Została wykorzystana funkcja MSE, opisana wcześniej w zadaniu zwiększania rozdzielczości. W tym przypadku porównuje ona obraz odszumiony przez model z obrazem oryginalnym.

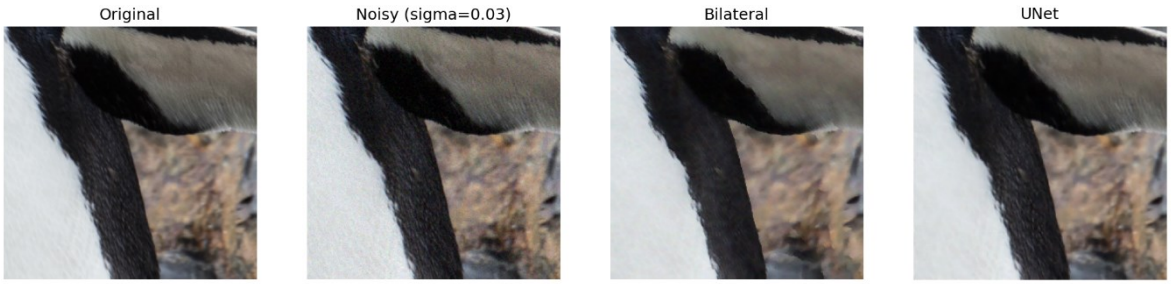
2.3 Wyniki

Wyniki stanowią średnie dla 100 obrazów walidacyjnych.

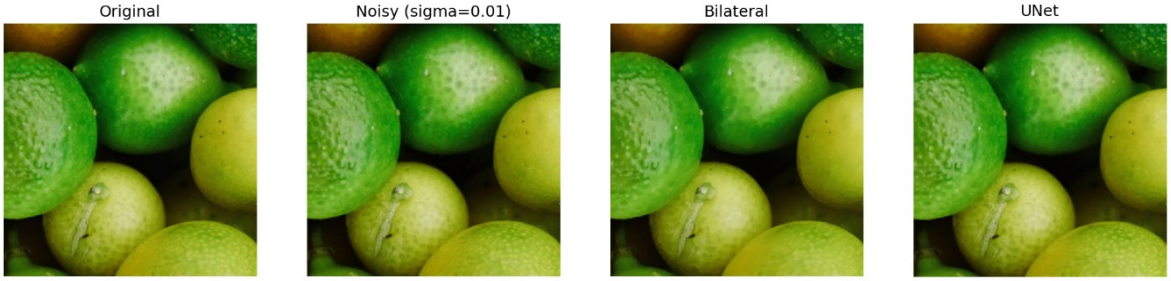
σ	Metoda	SNE	PSNR	SSIM	LPIPS
0,01	Obraz zaszumiony	19,4183	40,0556	0,9670	0,0429
0,01	Filtr bilateralny	43,6521	36,8249	0,9596	0,0920
0,01	U-Net	8,6221	43,7027	0,9888	0,0235
0,03	Obraz zaszumiony	171,7392	30,5927	0,8029	0,1757
0,03	Filtr bilateralny	182,3657	30,6967	0,8574	0,2076
0,03	U-Net	42,4947	36,8900	0,9563	0,0910



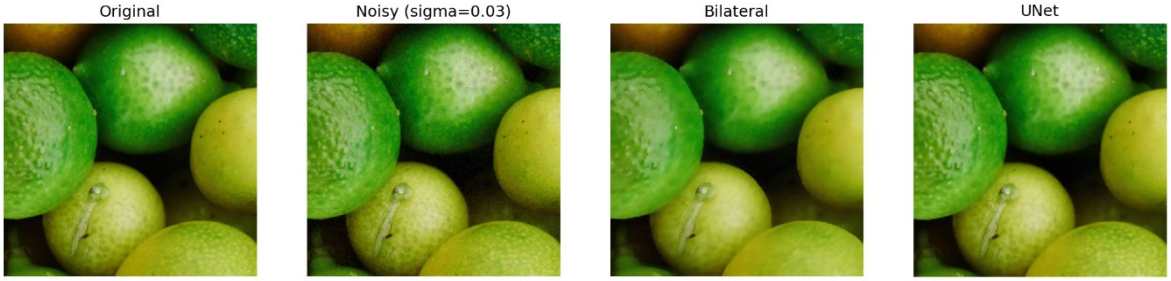
Rysunek 7 Odszumianie dla σ = 0,01



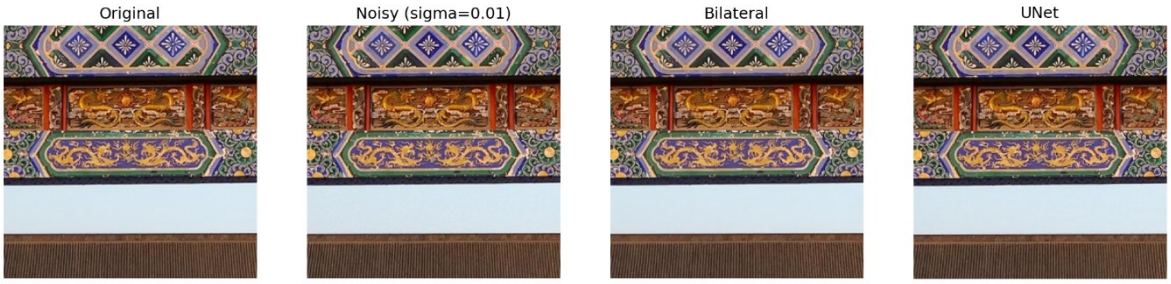
Rysunek 8 Odszumianie dla σ = 0,03



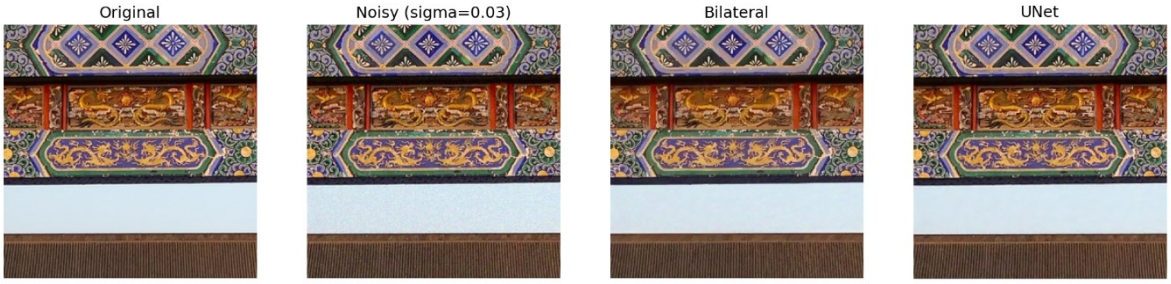
Rysunek 9 Odszumianie dla σ = 0,01



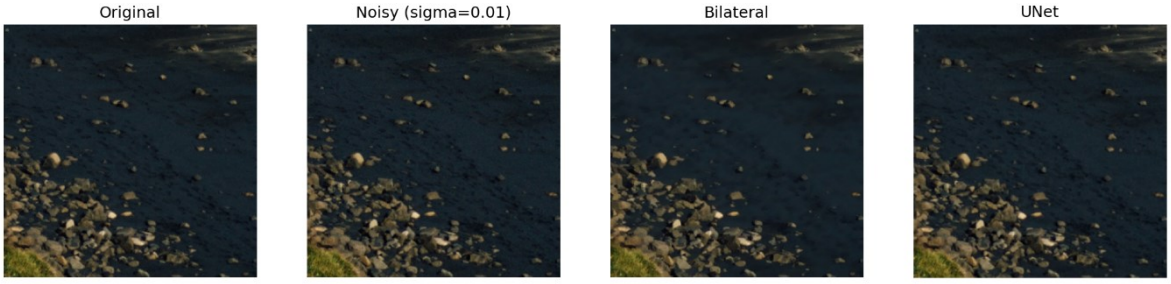
Rysunek 10 Odszumianie dla σ = 0,03



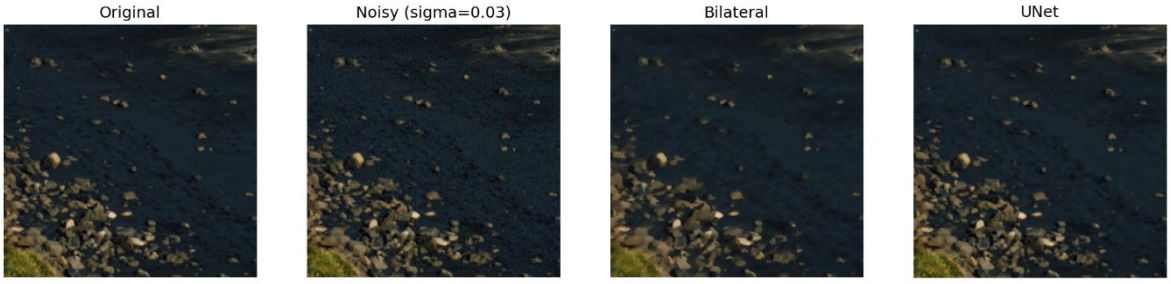
Rysunek 11 Odszumianie dla σ = 0,01



Rysunek 12 Odszumianie dla σ = 0,03



Rysunek 13 Odszumianie dla σ = 0,01



Rysunek 14 Odszumianie dla σ = 0,03

2.4 Wnioski

U-Net uzyskał najlepsze wyniki we wszystkich metrykach dla obu poziomów szumu. Względem filtra bilateralnego poprawił PSNR o około 6,88 dB dla σ = 0,01 i 6,19 dB dla σ = 0,03.

Dla σ = 0,01 filtr bilateralny pogorszył wszystkie metryki względem obrazu zaszumionego. W zastosowanej konfiguracji wygładzanie powodowało utratę szczegółów. Dla σ = 0,03 filtr poprawił PSNR i SSIM, ale pogorszył SNE i LPIPS.